

기술명세서 (Technical Specification)

프로젝트명 AI 독립검증 기반 보이스피싱 금융안전 서비스

팀명 가드레일즈

문서 버전 v0.1 (초안)

작성일 2026-08-26

작성자 (담당자명)

이 문서는 작성 예시입니다. 대괄호 [] 표시된 부분은 팀에서 확정해 채워 넣으세요.
TBD 는 아직 결정되지 않은 항목이며, 결정 기한을 함께 적어두면 관리가 쉽습니다.

1. 소개 및 시스템 개요

1.1 목적

통화 중 형성되는 잘못된 판단이 금융 피해로 이어지기 전에, AI가 위험을 탐지하고 외부의 독립적인 주체가 상황을 검증하며, 검증이 끝날 때까지 위험한 금융거래를 일시 보류하는 구조를 제공한다.

본 서비스는 사용자의 판단을 대신하지 않는다. 피해로 연결되기 전에 한 번 더 멈추는 것을 목표로 한다.

1.2 범위

MVP 구현 대상

구분	내용
통화 위험 탐지	통화 스크립트를 입력받아 위험도와 근거를 산출
역할별 브리프	수신 주체별로 정보를 분리해 생성
신뢰인 알림	사전 동의한 신뢰인에게 판정 결과 발송

MVP 범위 외 (시뮬레이션으로 대체)

구분	사유	대체 방식
송금 보류	금융기관 API 미개방	화면 목업으로 시연
기관 진위확인	공식기관 API 미개방	화면 목업으로 시연
실시간 통화 스트리밍	STT 실시간 처리 난이도	녹음 파일 / 스크립트 업로드

범위 외 항목을 명시하는 이유: 구현하지 못한 것이 아니라, 의도적으로 범위를 조정했음을 문서로 남기기 위함이다. 발표 시 질문에 대한 답변 근거가 된다.

1.3 용어 정의

용어	정의
신뢰인	사용자가 사전 등록하고 동의를 받은 공동검토 대상자
브리프	분석 결과를 수신 주체별로 필터링해 생성한 요약 정보
판단불가	근거가 부족해 위험도를 산출하지 않는 상태
판정 결과	위험도, 위험 유형, 요구 금액. 통화 원문은 포함하지 않음
온디바이스	데이터를 외부로 전송하지 않고 기기 내부에서만 처리하는 방식

1.4 약어

약어	원어
STT	Speech To Text
LLM	Large Language Model
FDS	Fraud Detection System

1.5 관련 문서

- 03_제안서 본작성.pptx — 서비스 기획 및 문제정의
- [기능 요구사항 정의서(FRS) 링크]

2. 기능 요구사항 (FR)

FR-01 통화 위험 탐지

항목	내용
입력	통화 스크립트 (텍스트, 50자 이상 5000자 이하)
처리	LLM 기반 3요소 분석 (아래 판단 기준 참조)
출력	위험도(0-100), 판정, 근거 배열

판단 기준 (제안서 12장 전략 분석과 동일)

번호	요소	탐지 대상
1	정보 우위	개인정보·절차를 상세히 언급해 신뢰를 형성
2	심리적 압박	권위, 공포, 긴급성으로 검토 시간을 축소
3	외부 검증 차단	비밀유지 요구, 가족·기관 확인 방해

판정 규칙

- 근거 2개 이상 → 위험
- 근거 1개 → 주의
- 근거 0개 → 정상
- 근거를 원문에서 인용할 수 없는 경우 → 판단불가

처리 제약

- 근거는 반드시 입력 원문에서 인용한다. 추정하거나 생성하지 않는다.
- 판단이 애매한 경우 임의로 판정하지 않고 판단불가 를 반환한다.

FR-02 역할별 브리프 생성

항목	내용
입력	FR-01 분석 결과
처리	수신 주체별 정보 필터링
출력	피해자용 브리프, 신뢰인용 브리프

수신 주체	포함 정보	제외 정보
사용자 본인	위험도, 근거(원문 인용 포함), 행동 안내	—
신뢰인	위험도, 위험 유형, 요구 금액	통화 원문, 상대방 발화 인용, 상대방 번호

신뢰인에게 통화 원문을 전송하지 않는 이유는 6.2 법적 제약을 참조한다.

FR-03 신뢰인 알림 발송

항목	내용
입력	FR-02 신뢰인용 브리프, 신뢰인 ID
처리	사전 동의 여부 확인 → 미동의 시 발송 차단
출력	발송 결과 (성공 / 미동의 / 발송실패)

처리 제약

- 동의 시각(`consent_at`)이 기록되지 않은 신뢰인에게는 발송하지 않는다.
- 발송 실패 시 재시도는 [최대 N회 / TBD]로 제한한다.

FR-04 신뢰인 등록 및 동의 획득

항목	내용
입력	신뢰인 연락처, 관계
처리	동의 요청 발송 → 동의 확인 → 동의 시각 기록
출력	등록 완료 여부

3. 비기능 요구사항 (NFR)

구분	요구사항	측정 기준
성능	분석 응답 시간	LLM 호출 포함 [10]초 이내
성능	동시 처리	[TBD]
보안	통화 원문 미저장	분석 완료 후 즉시 폐기, DB 컬럼 미존재
보안	전송 데이터 최소화	신뢰인 전송 시 원문 및 상대방 발화 제외
보안	통신 구간 암호화	전 구간 HTTPS
확장성	LLM 교체 가능성	추론 호출부를 인터페이스로 분리
이식성	온디바이스 전환 가능성	분석 모듈을 독립 컴포넌트로 설계
가용성	LLM 장애 대응	임의 판정 금지, 분석 불가 명시 반환

이식성 항목 해설
MVP는 서버 기반 분석으로 구현하되, 향후 경량 모델을 기기 내부에 탑재하는 전환이 가능하도록 분석 모듈을 독립적으로 설계한다. 상세 근거는 6.1 참조.

4. 외부 인터페이스 명세

4.1 사용자 인터페이스 (UI)

화면	기능
스크립트 입력	녹음 파일 업로드 또는 텍스트 직접 입력
분석 결과	위험도, 근거, 행동 안내 표시
신뢰인 관리	신뢰인 등록, 동의 상태 확인, 삭제
송금 보류 (목업)	시뮬레이션 화면 — 실제 연동 없음

4.2 내부 API 명세

POST /api/analyze

통화 스크립트를 분석해 위험도와 근거를 반환한다.

요청

```
{
  "transcript": "고객님 금융감독원입니다. 계좌가 범칙에 연루되어 지금 즉시 안전계좌로 이체하셔야 합니다. 가족에게는 알리지 마세요."
}
```

응답 (정상)

```
{
  "analysis_id": "a_20260826_001",
  "risk_score": 87,
  "verdict": "위험",
  "evidence": [
    { "type": "정보 우위", "quote": "금융감독원입니다" },
    { "type": "심리적 압박", "quote": "지금 즉시 안전계좌로 이체" },
    { "type": "외부 검증 차단", "quote": "가족에게는 알리지 마세요" }
  ],
  "requested_amount": null
}
```

응답 (판단불가)

```
{
  "analysis_id": "a_20260826_002",
  "verdict": "판단불가",
  "reason": "입력 내용이 50자 미만입니다"
}
```

에러 응답

코드	상황	응답
400	입력 길이 위반	{ "error": "INVALID_INPUT" }
503	LLM 호출 실패	{ "error": "LLM_UNAVAILABLE" }
504	응답 시간 초과	{ "error": "TIMEOUT" }

에러 시에도 임의 판정을 반환하지 않는다. 분석 불가 상태를 사용자에게 그대로 알린다.

POST /api/brief

분석 결과를 수신 주체별 브리프로 변환한다.

요청

```
{ "analysis_id": "a_20260826_001", "audience": "trusted_contact" }
```

응답

```
{
  "risk_score": 87,
  "risk_types": ["기관 사칭", "긴급성 압박", "외부 검증 차단"],
  "requested_amount": 3000000
}
```

audience 가 trusted_contact 인 경우 evidence 의 quote 필드는 응답에 포함하지 않는다.

POST /api/notify

신뢰인에게 브리프를 발송한다.

요청

```
{ "analysis_id": "a_20260826_001", "contact_id": 12 }
```

응답

```
{ "status": "sent" }
```

status	의미
sent	발송 완료
blocked_no_consent	동의 기록 없음 — 발송하지 않음
failed	발송 실패

4.3 외부 시스템 연계

시스템	용도	연동 여부
LLM API	통화 내용 분석	연동
STT API	음성 → 텍스트 변환	[연동 / TBD]
알림 발송 API	신뢰인 알림	연동
금융기관 송금 보류 API	송금 방지턱	미연동 (범위 외)
공식기관 진위확인 API	독립 검증	미연동 (범위 외)

5. 데이터 명세

5.1 테이블 정의

users

컬럼	타입	설명
id	BIGINT PK	사용자 ID
phone	VARCHAR(20)	연락처
created_at	DATETIME	가입 시각

trusted_contacts

컬럼	타입	설명
id	BIGINT PK	신뢰인 ID
user_id	BIGINT FK	등록한 사용자
name	VARCHAR(50)	이름
contact	VARCHAR(20)	연락처
consent_at	DATETIME NULL	동의 시각. NULL이면 발송 차단

analyses


컬럼	타입	설명
id	BIGINT PK	분석 ID
user_id	BIGINT FK	사용자
risk_score	INT NULL	위험도 0-100
verdict	VARCHAR(20)	위험 / 주의 / 정상 / 판단불가
requested_amount	BIGINT NULL	요구 금액
created_at	DATETIME	분석 시각

통화 원문 컬럼은 존재하지 않는다. 스키마 차원에서 저장을 불가능하게 한다.

evidences

컬럼	타입	설명
id	BIGINT PK	근거 ID
analysis_id	BIGINT FK	분석
type	VARCHAR(30)	위험 유형
quote	VARCHAR(200)	원문 인용 — 본인에게만 노출

5.2 데이터 흐름



6. 제약조건 및 설계 가정

6.1 기술 제약

대형 LLM의 온디바이스 실행 불가

대형 LLM은 파라미터 수가 수백억 개 이상으로, 실행에 필요한 메모리가 수십 GB를 초과한다. 일반 스마트폰의 RAM(8-16GB)으로는 적재할 수 없다.

기기 내부 실행을 위해서는 소형 모델(1-3B급)로의 경량화와 양자화, 모바일 배포가 별도로 필요하며, 이는 MVP 개발 기간 내 수행이 어렵다.

따라서 본 MVP는 서버 기반 분석으로 구현한다.

상용화 단계에서 경량 모델 온디바이스 전환을 로드맵으로 둔다 (NFR 이식성 참조).

단계	분석 위치	사용 모델
MVP	서버	대형 LLM API
상용화	기기 내부	경량화 모델

입력 방식 제약

실시간 통화 스트리밍 STT는 지연시간과 비용 문제로 MVP 범위에서 제외한다.

녹음 파일 또는 텍스트 스크립트 업로드 방식으로 대체하며, 분석 로직은 동일하다.

6.2 법적 제약

통화 녹음 및 분석

- 통신비밀보호법은 제3자에 의한 감청과 타인 간 대화의 녹음을 금지한다.
- 본 서비스는 사용자 **본인이 당사자인 통화**를, **본인 동의 하에** 처리한다.
- 통신사와 달리 본 서비스는 통신 매개자가 아니므로 온디바이스 처리가 법적 필수 요건은 아니다.

신뢰인 전송

- 통화 상대방은 본 서비스에 동의한 바 없으므로, 상대방의 발화를 제3자에게 전달하지 않는다.
- 분석 시점에는 상대방이 사기범인지 확정되지 않았다. 오탐 시 무고한 제3자의

발화가 "사기 정황"으로 전달될 위험이 있다.

- 따라서 신뢰인에게는 **판정 결과만** 전송한다 (FR-02 참조).

구분	전송	미전송
신뢰인	위험도, 위험 유형, 요구 금액	통화 원문, 상대방 발화 인용, 상대방 번호

이 구조는 SKT 가족 케어가 가족·지인에게 탐지 결과만 전달하는 방식, 그리고 통신사가 ASAP 플랫폼에 통화 내용 대신 위험 신호만 공유하는 방식과 동일한 설계 원칙을 따른다.

개인정보 처리

- 통화 원문은 분석 완료 후 즉시 폐기하며 저장하지 않는다.
- 신뢰인 등록 시 사전 동의를 획득하고 동의 시각을 기록한다.

6.3 설계 가정

항목	가정
기기	사용자는 통화 녹음이 가능한 안드로이드 기기를 사용한다
신뢰인	사전 등록 및 동의를 완료한 상태다
외부 연동	금융기관·공식기관 API는 MVP에서 연동하지 않는다
언어	입력 통화는 한국어로 한정한다

6.4 기술 스택

구분	선택	선정 사유
언어	Python	LLM·STT 라이브러리 생태계
백엔드	FastAPI	비동기 처리, LLM 호출 지연 대응
DB	MySQL	팀 숙련도
프론트	React	팀 숙련도
외부	LLM API, STT API	자체 학습 대비 개발 기간 단축

7. 미결정 사항

번호	항목	결정 기한	담당
1	STT 연동 여부 및 사용 API	[]	[]
2	동시 처리 성능 목표치	[]	[]
3	알림 발송 채널 (SMS / 푸시 / 메신저)	[]	[]
4	요구 금액 추출 방식	[]	[]

문서 이력

버전	일자	변경 내용	작성자
v0.1	2026-08-26	초안 작성	